

Informe de Desempeño y Validación del Modelo

1. Elección del Modelo

Tras experimentar con diversos algoritmos (SVM, Random Forest, Naive Bayes y KNN), el modelo **K-Nearest Neighbors (KNN)** fue seleccionado como el más adecuado.

Esto debido a que los datos presentan una estructura donde la similitud local (proximidad geométrica entre píxeles de granos del mismo tipo) es el predictor más fuerte. A diferencia de SVM, que buscaba una separación lineal inexistente, KNN captura grupos naturales de características con una precisión del **72.22%**.

SVM (Lineal)	Accuracy: 0.5556
Random Forest	Accuracy: 0.6667
KNN (k=3)	Accuracy: 0.7222
Naive Bayes	Accuracy: 0.6944

Figura 1. Resultados obtenidos tras realizar la experimentación.

2. Entrenamiento

El proceso se diseñó para ser 100% reproducible, para ellos se toma en cuenta los siguientes puntos:

- División de datos: Se utilizó una semilla aleatoria (`random_state=42`) para asegurar que la partición de las 144 muestras de entrenamiento y las 36 de prueba sea siempre la misma, por ende, se utilizaron 6 datasets diferentes e incluyendo el propio.
- Escalado: Se implementó un `StandardScaler` ajustado únicamente con los datos de entrenamiento para evitar la fuga de información (*data leakage*).
- Consistencia: El conjunto de entrenamiento exacto fue exportado en `entrenamiento_final_144.csv` para auditorías futuras.

3. Métricas

Las métricas fueron calculadas mediante el método de *Hold-out* (80/20):

- **Accuracy Final:** 0.7222.
- **Comparativa:** Superó por un 2.78% a Naive Bayes y por un 5.55% a Random Forest.
- **Interpretación:** El modelo logra clasificar correctamente 7 de cada 10 granos desconocidos, un desempeño sólido considerando que el dataset es experimental y de tamaño reducido (180 muestras totales).

4. Exportación

Se generaron archivos binarios utilizando la librería *joblib* para garantizar que el modelo esté listo para producción:

- C32009_Juan_Chacón.joblib: Contiene la estructura y pesos del algoritmo entrenado.
- escalador.joblib: Contiene los parámetros de media y desviación estándar para normalizar datos nuevos.
- Estado: Verificado y funcional sin errores en entornos locales y remotos.

5. Generalización

El modelo demostró una buena capacidad de generalización al ser evaluado con el 20% de los datos que nunca vio durante el entrenamiento:

- Resultado en Test: El mantenimiento de una precisión del 72% en el conjunto de prueba indica que el modelo no ha caído en *overfitting* (sobreajuste), siendo capaz de identificar patrones en granos de arroz nuevos siempre que mantengan condiciones de iluminación y captura similares a las originales.

Nota conclusiva: Es importante reconocer que es posible mejorar el modelo y quizá cambié el algoritmo ya que aumentar el tamaño del dataset (más de 180 muestras) puede permitir que algoritmos como Random Forest o incluso SVM alcancen una precisión superior al 72%.